

# Introduction to Big Data Analytics

## Compressed Sensing and Sparse Representation

Yanwei Fu

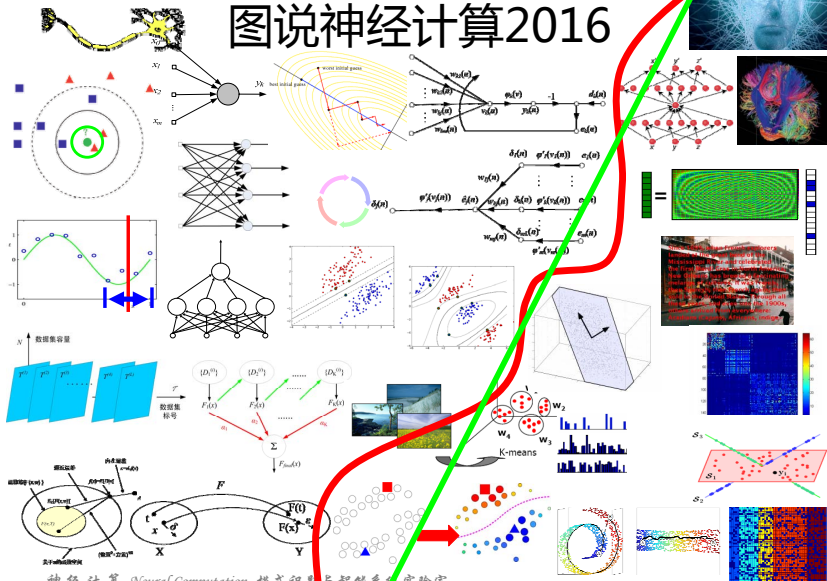
School of Data Science, Fudan University

# Compression and Hashing of Big Data

- Highly related to numerical computing, statistical theory
- Very useful in many practical applications
- Basic algorithms for advanced Big data analytics



# 图说神经计算2016

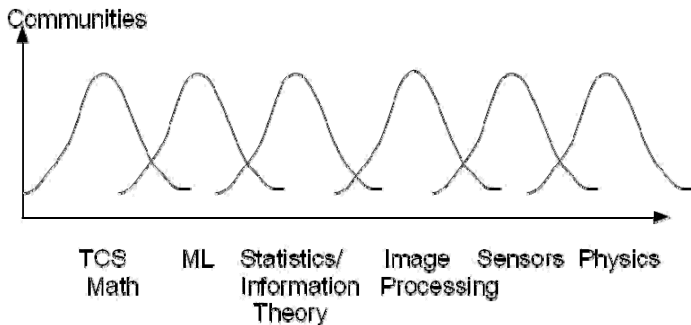


# 内容提要

- 引言
- 压缩感知
- 稀疏表示及其应用
  - SRC / SSC
- 矩阵恢复及其应用
  - LRMC / RPCA(PCP) / LRR
- 最优化问题求解算法
  - MP / OMP / FS / ADMM / (LADMM)

# 引言

- 压缩感知与稀疏表示
  - **Compressed Sensing & Sparse Representation**




# 传统数据获取: 采样 (Sampling)


- 采样定理

- 对于一个限带(band limited)信号 $x(t)$ , 准确重构所需要的最小采样速率为

$$f_{\text{sampling}} \geq 2f_{\text{max}}$$



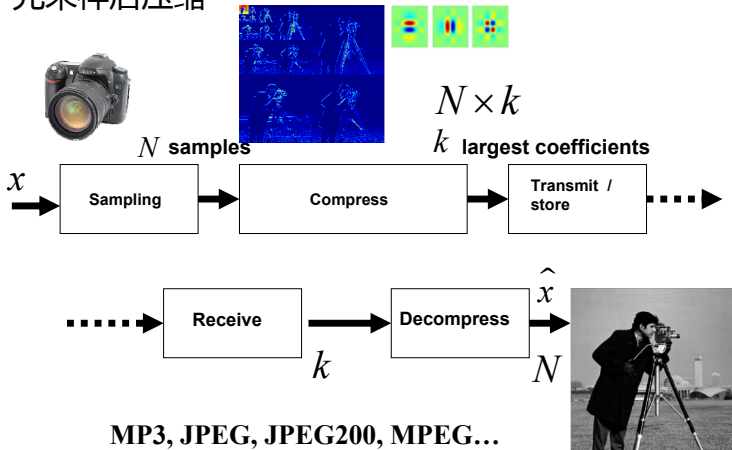
$$x[n] = x(nT), \quad n \in \mathbb{Z}$$



$$\hat{x}(t) = \sum_{n \in \mathbb{Z}} x[n] \text{sinc}\left(\frac{t}{T} - n\right)$$

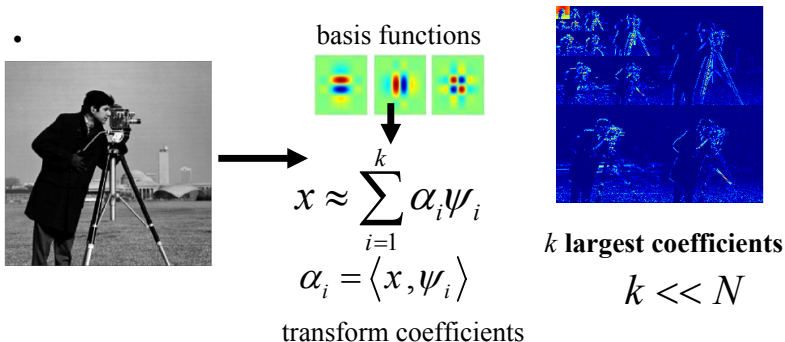
# 传统的数据压缩模式

- 先采样后压缩



MP3, JPEG, JPEG200, MPEG...



# 稀疏信号(Sparse Signal)



- 数字信号往往通常非常稀疏
  - 音频(Audio): MP3, AAC... ~10:1 压缩率
  - 图像/Images): JPEG, JPEG2000... ~20:1 压缩率
  - 视频序列(Video sequences): MPEG2, MPEG4... ~40:1 压缩率



# $k$ -稀疏信号( $k$ -Sparse Signal)



# 内容提要

- 引言
- 压缩感知
- 稀疏表示及其应用
  - SRC / SSC
- 矩阵恢复及其应用
  - LRMC / RPCA(PCP) / LRR
- 最优化问题求解算法
  - MP / OMP / FS / ADMM / (LADMM)

# 压缩感知框架

- 编码(Encoding):

- 获得**M**个测量系数**y**, 即  $\mathbf{y} = \Phi \mathbf{x} = \Phi \Psi \boldsymbol{\alpha} = \mathbf{A} \boldsymbol{\alpha}$ 
  - 其中  $\Phi$  称为感知矩阵,  $\Psi$  为稀疏化基或稀疏化变换

- 解码(Decoding):

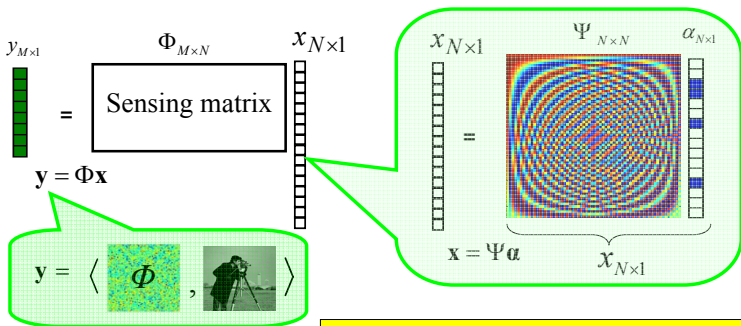
- 从测量向量**y** 借助稀疏先验(**sparse prior**)和非线性优化重构出待观测向量**x**
  - 求解 $\alpha$

$$\hat{\alpha} = \arg \min_{\alpha} \|\alpha\|_0 \quad \text{s.t.} \quad \mathbf{y} = \Phi \Psi \alpha$$

- 计算**x**:  $\hat{\mathbf{x}} = \Psi \hat{\alpha}$

# 压缩感知框架 — 编码过程

- 借助感知矩阵  $\Phi$  获得被观测向量  $x$  的一个  $M$  维测量，其中  $x$  在变换  $\Psi$  下是稀疏的




$\Phi$  与  $\Psi$  是不相干的(incoherent)


→  $y = \Phi \Psi \alpha = A \alpha$

# 压缩感知框架 — 编码过程

- $y = \Phi \Psi a = A a$



— 其中  $A = \Phi \Psi$  ,  
通常被称之为过完备词典(Over-complete Dictionary)




# 压缩感知框架 — 解码过程

- 给定完备词典A和测量y，重构出观测向量x

- 核心问题：如何有效和可靠地从  $y = A\alpha$  恢复出稀疏表示系数  $\alpha$
- 等价于求解欠定方程组

$$y = A\alpha$$



若无稀疏性先验(sparseness prior): underdetermined (ill-posed) 问题

若有稀疏性先验(sparseness prior): well-posed问题

# 压缩感知框架 — 解码过程

- 稀疏表示系数恢复，即下列优化问题：

$$P_0: \quad \hat{\alpha} = \arg \min_{\alpha} \|\alpha\|_0 \quad \text{s.t.} \quad \mathbf{y} = \mathbf{A}\alpha$$

Computationally intractable!  
A NP-hard Problem.

$$P_1: \quad \hat{\alpha} = \arg \min_{\alpha} \|\alpha\|_1 \quad \text{s.t.} \quad \mathbf{y} = \mathbf{A}\alpha$$

Computationally tractable!  
A Convex Problem

# 基的不相干性定义

- 不相干基(Incoherence bases)
  - 假设信号 $\mathbf{x}$ 在正交规范变换(Orthonormal transform) $\Psi$ 下是稀疏的, 即 $\mathbf{x} = \Psi\alpha$  其中 $\alpha$ 是 $k$ -稀疏的
  - 借助感知矩阵 $\Phi$ 获取 $M$ 个测量,


$$\mathbf{y} = \Phi\mathbf{x} = \Phi\Psi\alpha = \mathbf{A}\alpha$$

其中 $\mathbf{y}$ 是 $M$ 维列向量,  $\mathbf{A} = \Phi\Psi$

则 $\Psi$ 与 $\Phi$ 之间的相干性(coherence)定义为

$$\mu(A) = \mu(\Phi, \Psi) = \sqrt{N} \max_{1 \leq i, j \leq N} \left| \langle \varphi_i^T, \psi_j \rangle \right|$$

其中  $\varphi_i$ : rows of  $\Phi$        $\psi_j$ : columns of  $\Psi$






# 不相干基的性质

- 相干性(coherence)的范围:  $1 \leq \mu(\Phi, \Psi) \leq \sqrt{N}$ 
  - 如果  $\mu$  比较小, 则称基是不相干的(Incoherent)
- 直观解释:
  - 当两个基是不相干的, 则  $\mathbf{A}$  中的元素分布得比较分散(spread out), 其中  $\mathbf{A} = \Phi \Psi$
  - 借助感知矩阵  $\Phi$  获取  $m$  个测量,  $M$  个测量中的每个测量只包含信号  $\mathbf{x}$  的少量信息
    - 我们希望相干性小
- 不相干基举例:
  - DFT 和单位阵  $\mathbf{I}$ :


$$\mu = 1$$

- 高斯或Bernoulli矩阵和任何其它基:

$$\mu = \sqrt{2 \log N}$$



# RIP (Restricted Isometry Property)



- 准确信号恢复的充分条件:

$$(1 - \varepsilon) \|\alpha_k\|_2^2 \leq \|A_k \alpha_k\|_2^2 \leq (1 + \varepsilon) \|\alpha_k\|_2^2$$

所有由A的k列构成的子矩阵近似正交

# 准确信号恢复所需的测量数目

- $$\min_{\alpha} \|\alpha\|_1, \text{ s. t. } \mathbf{y} = \mathbf{A}\alpha \quad (1)$$

- 定理(Candes, Romberg & Tao, 2006)

假设  $\alpha$  的 **support** 为  $T$ , 矩阵  $\mathbf{A}$  的  $m$  个行向量是从  $N \times N$  的 **DFT** 矩阵的  $N$  行中均匀地随机选出, 那么如果  $m$  满足条件:


$$m \geq C |T| \log N$$

则求解 **L1** 最小化问题(1) 将以概率至少  $1 - O(N^{-r})$  准确地恢复出  $\alpha$

实际上,  $m$  为 4-6 倍的  $|T|$  即可保证准确发现

# 从线性方程组求解看信号重构

- 考虑一个线性信号系统



$$\mathbf{y}_{M \times 1} = \mathbf{A}_{M \times N} \mathbf{\alpha}_{N \times 1}$$

- $M = N$ 
  - 方程数目等于未知数个数  $\rightarrow$  **Critical sampling**
    - 若方程满秩，则有唯一解  $\mathbf{\alpha} = \mathbf{A}^{-1} \mathbf{y}$
- $M > N$ 
  - 方程数目大于未知数个数  $\rightarrow$  **Over-sampling**
    - 若方程列满秩，则借助伪逆，可以得到方程唯一解  $\mathbf{\alpha} = \mathbf{A}^+ \mathbf{y}$
- $M < N$ 
  - 方程数目小于未知数个数  $\rightarrow$  **Under-sampling**
    - 无穷解
    - 如果解是稀疏的，则可以有唯一解  $\mathbf{\alpha}_s = \mathbf{A}_s^+ \mathbf{y}_s$

# 内容提要

- 引言
- 压缩感知
- 稀疏表示及其应用
  - SRC / SSC
- 矩阵恢复及其应用
  - LRMC / RPCA(PCP) / LRR
- 最优化问题求解算法
  - MP / OMP / FS / ADMM / (LADMM)

# 稀疏表示

- 给定完备词典A, 稀疏表示通过求解下述模型完成:

– 使用 $L_0$ 范数

Combinatorial problem

$$\hat{\alpha} = \arg \min_{\alpha} \|\alpha\|_0 \quad \text{s.t.} \quad y = A\alpha$$

$$\hat{\alpha} = \arg \min_{\alpha} \|\alpha\|_0 \quad \text{s.t.} \quad \|y - A\alpha\|_2^2 \leq \delta$$



– 使用 $L_1$ 范数

$$\hat{\alpha} = \arg \min_{\alpha} \|\alpha\|_1 \quad \text{s.t.} \quad y = A\alpha$$

$$\hat{\alpha} = \arg \min_{\alpha} \|\alpha\|_1 \quad \text{s.t.} \quad \|y - A\alpha\|_2^2 \leq \delta$$

Convex problem

# Why Is L1 Better Than L2?



The line  $\mathbf{y} = \mathbf{A}\mathbf{a}$  intersect  $L_2$  circle at a non-sparse point

The line  $\mathbf{y} = \mathbf{A}\mathbf{a}$  intersect  $L_1$  diamond at the sparse point



Unique and exact solution

# 稀疏表示的典型应用

- 稀疏表示被广泛应用于信号去噪、恢复、增强中，也被应用于人脸识别、子空间聚类以及特征学习等方面
  - 图像去噪(De-noising)
  - 图像增强(Enhancement)
  - 光照变化条件下的正面人脸图像识别
  - 子空间聚类
    - 运动分割(Motion Segmentation)
  - 转换学习(Transfer Learning)
    - Self-Taught Learning



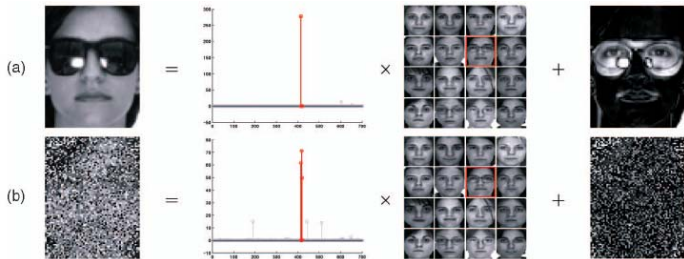
# 基于稀疏表示的人脸识别

- 把训练数据作为词典A，计算测试数据的稀疏表示，根据稀疏表示的系数进行分类

$$A = [A_1, A_2, \dots, A_k]$$

$$\min_{\mathbf{x}} \|\mathbf{x}\|_1 + \lambda \|\mathbf{y} - A\mathbf{x}\|_2^2$$

$$\min_{\mathbf{x}, \mathbf{e}} \|\mathbf{x}\|_1 + \lambda \|\mathbf{e}\|_1 \quad \text{s.t.} \quad \mathbf{y} = A\mathbf{x} + \mathbf{e}$$



J. Wright et al.: Robust Face Recognition via Sparse Representation, TPAMI 2009.

# SRC 算法

- **Algorithm 1. Sparse Representation-based Classification (SRC)**

1: **Input:** a matrix of training samples

$A = [A_1, A_2, \dots, A_k] \in \mathbb{R}^{m \times n}$  for  $k$  classes, a test sample  $y \in \mathbb{R}^m$ , (and an optional error tolerance  $\varepsilon > 0$ .)

2: Normalize the columns of  $A$  to have unit  $\ell^2$ -norm.

3: Solve the  $\ell^1$ -minimization problem:

$$\hat{x}_1 = \arg \min_x \|x\|_1 \quad \text{subject to} \quad Ax = y. \quad (13)$$

(Or alternatively, solve

$$\hat{x}_1 = \arg \min_x \|x\|_1 \quad \text{subject to} \quad \|Ax - y\|_2 \leq \varepsilon.)$$

4: Compute the residuals  $r_i(y) = \|y - A \delta_i(\hat{x}_1)\|_2$   
for  $i = 1, \dots, k$ .

5: **Output:**  $\text{identity}(y) = \arg \min_i r_i(y)$ .

J. Wright et al.: Robust Face Recognition via Sparse Representation, TPAMI 2009.

神经计算-Neural Computation 模式识别与智能系统实验室

# 稀疏子空间聚类(SSC)




- 子空间聚类(Subspace Clustering)
  - 给定一组分布在 $k$ 个子空间上的数据点,  
把数据点分成 $k$ 个子空间
- 以数据矩阵 $Y$ 本身作为词典(dictionary),  
寻找最稀疏的自表示(Self-Expression)

$$\min_C \|C\|_0 \quad \text{s.t.} \quad Y = YC, \quad \text{diag}(C) = 0$$

↪

$$\min_C \|C\|_1 \quad \text{s.t.} \quad Y = YC, \quad \text{diag}(C) = 0$$

- 应用: (1) 运动分割;  
(2) 人脸图像聚类



# SSC算法

---

**Algorithm 1 : Sparse Subspace Clustering (SSC)**

---

**Input:** A set of points  $\{\mathbf{y}_i\}_{i=1}^N$  lying in a union of  $n$  linear subspaces  $\{\mathcal{S}_i\}_{i=1}^n$ .

- 1: Solve the sparse optimization program:

$$\min \|\mathbf{C}\|_1 \quad \text{s.t.} \quad \mathbf{Y} = \mathbf{Y}\mathbf{C}, \quad \text{diag}(\mathbf{C}) = \mathbf{0}.$$

- 2: Form a similarity graph by connecting node  $i$ , representing  $\mathbf{y}_i$ , to node  $j$ , representing  $\mathbf{y}_j$ , by an edge whose weight is equal to  $w_{ij} = |c_{ij}| + |c_{ji}|$ .
- 3: Infer the segmentation of the data from the  $n+1$  eigenvectors of the symmetric normalized Laplacian matrix of the graph corresponding to its  $n+1$  smallest eigenvalues using the K-means algorithm.

**Output:** Segmentation of the data:  $\mathbf{Y}_1, \mathbf{Y}_2, \dots, \mathbf{Y}_n$ .

---

$$\min_{\mathbf{C}, \mathbf{E}} \|\mathbf{C}\|_1 + \lambda \|\mathbf{E}\|_F \quad \text{s.t.} \quad \mathbf{Y} = \mathbf{Y}\mathbf{C} + \mathbf{E}, \quad \text{diag}(\mathbf{C}) = \mathbf{0}$$


$$\min_{\mathbf{C}, \mathbf{E}} \|\mathbf{C}\|_1 + \lambda \|\mathbf{Y} - \mathbf{Y}\mathbf{C} - \mathbf{E}\|_F + \gamma \|\mathbf{E}\|_1 \quad \text{s.t.} \quad \text{diag}(\mathbf{C}) = \mathbf{0}$$

# 内容提要

- 引言
- 压缩感知
- 稀疏表示及其应用
  - SRC / SSC
- 矩阵恢复及其应用
  - LRMC / RPCA(PCP) / LRR
- 最优化问题求解算法
  - MP / OMP / FS / ADMM / (LADMM)

# 矩阵填充(Matrix Completion)

- 动机:
  - 观测到部分数据
  - 把缺失数据准确填充, 获得准确的完整数据 $X$



- 基本假设:
  - 数据 $X$ 是低秩的(**Low-Rank**), 观测到的元素是随机均匀分布的
  - 矩阵 $X$ 满足一定的不相干条件
- 基本模型:  $\min_D \text{rank}(D) \text{ s.t. } P_{\Omega}(D) = P_{\Omega}(X)$



$$\min_D \|D\|_* \text{ s.t. } P_{\Omega}(D) = P_{\Omega}(X)$$

E. J. Candès and B. Recht: Exact matrix completion via convex optimization, 2009.

E. Candès and T. Tao: The power of convex relaxation: Near-optimal matrix completion, 2009.

# 低秩矩阵填充(LRMC)

- 最优化问题:

$$\min_D \|D\|_* \quad \text{s.t.} \quad P_\Omega(D) = P_\Omega(X)$$

- 理论保证:

- 如果矩阵 $X$ 满足一定的不相干(Incoherence)条件, 观测的元素均匀分布, 则当观测的元素数 $k$ 满足下述条件

$$k > C \cdot r \cdot m \log^2 m$$

则以极高的成功概率保证求解该凸优化问题能够得到准确的矩阵 $X$

- 如何求解:

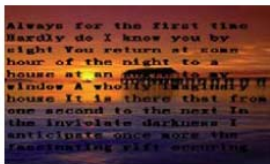
Benjamin Recht, "A Simpler Approach to Matrix Completion", Journal of Machine Learning Research Vol. 12, (2011), pp. 3413-3430.

# LRMC应用举例: Image inpainting

- 



(a) original image



(b) masked image



Debin Zhang et al. Matrix completion by Truncated Nuclear Norm Regularization, CVPR 2012.

神经计算-Neural Computation 模式识别与智能系统实验室



# LRMC应用举例: Image inpainting




Debin Zhang et al. Matrix completion by Truncated Nuclear Norm Regularization, CVPR 2012.

神经计算-Neural Computation 模式识别与智能系统实验室

# RPCA: Robust PCA

Wright et al. NIPS2009

- 动机:
  - 从被噪声污染的数据 $X$ 中恢复出干净数据 $D_0$ , 分离出噪声污染 $E_0$ 
    - $X = D + E$



- 基本假设:
  - 噪声 $E_0$ 是稀疏的, 数据 $D_0$ 是低秩的, 矩阵 $D_0$ 满足一定的不相干条件
- 基本模型:

$$\min_{D,E} \text{rank}(D) + \lambda \|E\|_0 \quad \text{s.t.} \quad X = D + E$$

↻

$$\min_{D,E} \|D\|_* + \lambda \|E\|_1 \quad \text{s.t.} \quad X = D + E$$

# RPCA: Robust PCA

- 优化问题:

PCP: Principal Component Pursuit:

$$\min_{D,E} \|D\|_* + \lambda \|E\|_1 \quad \text{s.t.} \quad X = D + E$$

- 理论保证:

- 在满足一定条件下，以高概率保证通过求解上述凸优化问题能够恢复出准确的数据矩阵 $D_0$ 和噪声干扰 $E_0$ ，其中

$$\lambda = 1 / \sqrt{m}$$

$D$  是大小为  $n_1 \times n_2$  的矩阵  $m = \max \{n_1, n_2\}$

Emmanuel J. Candes, Xiaolong Li, Yi Ma, and John Wright: Robust Principal Component Analysis? Journal of the ACM, 2011.

# RPCA应用: 视频中背景与目标分离

• 
$$X = D + E$$




(a)

(b)


(c)

# RPCA应用: 歌声与背景音乐的分离



- Songs (STFT)



Low-rank (music)



Sparse (voices)



Min, Zhang, Wright, Ma, CIKM 2010 / Sprechmann, Bronstein, Sapiro, ISMIR 2012

神经计算-Neural Computation 模式识别与智能系统实验室


# 低秩表示(LRR)

- Low-Rank Representation
  - 以数据矩阵 $X$ 本身作为词典(dictionary)  $A$ , 寻找最低秩的自表示(Self-Expression)

$$\min_Z \text{rank}(Z) \quad \text{s.t.} \quad X = XZ$$

$$\min_Z \|Z\|_* \quad \text{s.t.} \quad X = XZ$$

$$\min_{Z, E} \|Z\|_* + \lambda \|E\|_{2,1} \quad \text{s.t.} \quad X = XZ + E$$



G.Liu et al.: Robust Subspace Segmentation by Low-Rank Representation, ICML2010, TPAMI 2013.

# 内容提要

- 引言
- 压缩感知
- 稀疏表示及其应用
  - SRC / SSC
- 矩阵恢复及其应用
  - LRMC / RPCA(PCP) / LRR
- 目标函数不可微的带约束最优化问题求解
  - MP / OMP / FS / ISTA / FISTA / ADMM / (LADMM)

# 最优化问题

- 形式上的区别
  - 目标函数可导且无约束
  - 目标函数可导但有约束
  - 目标函数不可导但无约束
    - 比如: L1范数, 核(Nuclear)范数
  - 目标函数不可导且有约束
- 本质上的区别
  - 凸(convex)优化问题
  - 非凸(nonconvex)优化问题



# $L_0$ -最小化问题

- 以 $L_0$ 范数为目标函数，寻找最稀疏表示

$$\min_{\alpha} \|\alpha\|_0 \quad \text{s.t.} \quad y = A\alpha$$

Combinatorial problem

- 若考虑到高斯噪声，则：


$$\min_{\alpha} \|\alpha\|_0 \quad \text{s.t.} \quad \|y - A\alpha\|_2^2 \leq \delta$$

- 若考虑到稀疏噪声，则：

$$\min_{\alpha} \|\alpha\|_0 \quad \text{s.t.} \quad \|y - A\alpha\|_1 \leq \delta$$

# $L_0$ -最小化问题的求解

- 贪婪(Greedy)算法
  - 匹配追踪(Matching Pursuit: MP)
  - 正交匹配追踪(Orthogonal Matching Pursuit: OMP)



在每次迭代过程中，  
尝试确认出字典A中  
与非零表示系数相对  
应的列

# 匹配追踪(MP)

- 基本思想:
  - 每次迭代时, 尝试确认出最突出的基向量
- 算法步骤:
  - 1. 令 $t=1$ , 设置残差向量  $\mathbf{r}_t = \mathbf{y}$  和下标集  $I_t = \emptyset$
  - 2. 寻找与残差相关度最大的基向量下标
$$j = \arg \max_{1 \leq i \leq N} |\langle \mathbf{r}_t, \mathbf{a}_i \rangle|$$
, 加入下标集  $I_t \leftarrow I_t \cup \{j\}$
  - 3. 更新残差  $\mathbf{r}_{t+1} = \mathbf{r}_t - \langle \mathbf{r}_t, \mathbf{a}_j \rangle \mathbf{a}_j$
  - 4. 若 $t=k$ , 则停止; 否则, 令 $t \leftarrow t+1$ , 转第2步.

S. Mallat and Z. Zhang: Matching pursuit in a time-frequency dictionary, IEEE Trans. Signal Proc., 41 (1993), pp. 3397–3415.

神经计算-Neural Computation 模式识别与智能系统实验室

# 正交匹配追踪(OMP)


- 基本思想:
  - 保证残差与此前所选择的所有基向量正交
- 算法步骤:
  - 1. 令 $t=1$ , 设置残差向量  $\mathbf{r}_t = \mathbf{y}$  和下标集  $I_t = \emptyset$
  - 2. 寻找与残差相关度最大的基向量下标
$$j = \arg \max_{1 \leq i \leq N} |\langle \mathbf{r}_t, \mathbf{a}_i \rangle|$$
, 加入下标集  $I_t \leftarrow I_t \cup \{j\}$
  - 3. 计算表达系数  $\mathbf{c}_t^* = \arg \min_{\mathbf{c}} \|\mathbf{y} - A_{I_t} \mathbf{c}\|_2^2$
  - 5. 更新残差  $\mathbf{r}_{t+1} = \mathbf{y} - A_{I_t} \mathbf{c}_t^*$
  - 6. 若 $t=k$ , 则停止; 否则, 令 $t \leftarrow t+1$ , 转第2步.

Y. C. Pati, R. Rezaifar, and P. S. Krishnaprasad, "Orthogonal matching pursuit: recursive function approximation with applications to wavelet decomposition," in 27th Asilomar Conf. on Signals, Systems and Comput., Nov. 1993.

神经计算-Neural Computation 模式识别与智能系统实验室

# $L_1$ -最小化问题

- 把 $L_0$ 范数放松为 $L_1$ 范数 Combinatorial problem


$$\begin{aligned} \min_{\alpha} \|\alpha\|_0 \quad & \text{s.t.} \quad y = A\alpha \\ \min_{\alpha} \|\alpha\|_0 \quad & \text{s.t.} \quad \|y - A\alpha\|_2^2 \leq \delta \end{aligned}$$

$$\begin{aligned} \min_{\alpha} \|\alpha\|_1 \quad & \text{s.t.} \quad y = A\alpha \\ \min_{\alpha} \|\alpha\|_1 \quad & \text{s.t.} \quad \|y - A\alpha\|_2^2 \leq \delta \end{aligned}$$

Convex problem

# $L_1$ -最小化问题的求解

- 基追踪(Basis Pursuit: BP)
  - 使用变量分裂法转化为线性规划(Linear Programming)问题
    - 求解LP问题的方法，比如单纯形(Simplex)法 / 内点法(interior-point)
- 特征符号搜索(Feature Sign Search: FSS)
- 迭代收缩阈值算法(ISTA)
  - 快速迭代收缩阈值算法(FISTA)

[1] S. Chen, D. Donoho, and M. Saunders: Atomic Decomposition by Basis Pursuit, SIAM Review, Vol. 43, No. 1, pp. 129-159, 2001.

[2] H. Lee, A. Battle, R. Raina, and Andrew Y. Ng: Efficient Sparse Coding Algorithms, NIPS 2007.

神经计算-Neural Computation 模式识别与智能系统实验室

# 基追踪 (Basis Pursuit)

- 考虑优化问题  $\min \|\alpha\|_1 \quad \text{s.t.} \quad y = A\alpha$

令  $\alpha = u - v$  with  $u \geq 0, v \geq 0$

$$\text{则 } \|\alpha\|_1 = 1^T u + 1^T v \quad \text{令 } z \equiv \begin{bmatrix} u \\ v \end{bmatrix}; \quad B = \begin{bmatrix} A & -A \end{bmatrix}$$

从而

$$\begin{array}{ll} \min_{\alpha} \|\alpha\|_1 & \xrightarrow{\text{red arrow}} \min_z 1^T z \\ \text{s.t. } y = A\alpha & \text{s.t. } Bz = y, \quad z \geq 0 \end{array}$$

- 线性规划问题的算法: **Simplex / primal-dual interior-point / log-barrier...**

S. Chen, D. Donoho, and M. Saunders: Atomic Decomposition by Basis Pursuit, SIAM Review, Vol. 43, No. 1, pp. 129-159, 2001.

## $L_1$ -最小化问题的闭式解

- 考虑一个特殊的 $L_1$ -最小化问题 ( $A=I$ )

$$\min_{\mathbf{x}} \lambda \|\mathbf{x}\|_1 + \frac{1}{2} \|\mathbf{x} - \mathbf{c}\|_2^2$$

其最优解为:  $\mathbf{x}^* = T_\lambda(\mathbf{c})$

$$\text{— 其中 } x_j^* = T_\lambda(c_j) = \begin{cases} c_j - \lambda, & \text{if } c_j > \lambda \\ 0, & \text{if } |c_j| \leq \lambda \\ c_j + \lambda & \text{if } c_j < -\lambda \end{cases}$$

Soft-Thresholding 算子



# 特征符号搜索 (Feature Sign Search)

- Feature Sign Search 算法基本思路

- 考虑下述L1最小化问题

$$\arg \min_{\mathbf{x}} \|\mathbf{A}\mathbf{x} - \mathbf{y}\|_2^2 + \gamma \|\mathbf{x}\|_1$$

- 注意到问题的最优性条件为  $\frac{\partial \|\mathbf{A}\mathbf{x} - \mathbf{y}\|_2^2}{\partial \mathbf{x}} + \gamma \cdot \partial \|\mathbf{x}\|_1 = 0$

- 对于非零系数，有

$$\frac{\partial \|\mathbf{A}\mathbf{x} - \mathbf{y}\|_2^2}{\partial x_j} + \gamma \text{sign}(x_j) = 0$$

- 对于零系数，有

$$\left| \frac{\partial \|\mathbf{A}\mathbf{x} - \mathbf{y}\|_2^2}{\partial x_j} \right| \leq \gamma$$

- 如果 $\mathbf{x}$ 的分量的符号已知，则L1范数可被化简，相应的子问题转化为无约束二次规划(QP)问题

# Feature Sign Search 算法

## Algorithm 1 Feature-sign search algorithm

- 1 Initialize  $x := \vec{0}$ ,  $\theta := \vec{0}$ , and *active set*  $:= \{\}$ , where  $\theta_i \in \{-1, 0, 1\}$  denotes  $\text{sign}(x_i)$ .
- 2 From zero coefficients of  $x$ , select  $i = \arg \max_i \left| \frac{\partial \|y - Ax\|^2}{\partial x_i} \right|$ .  
Activate  $x_i$  (add  $i$  to the *active set*) only if it locally improves the objective, namely:  
If  $\frac{\partial \|y - Ax\|^2}{\partial x_i} > \gamma$ , then set  $\theta_i := -1$ , *active set*  $:= \{i\} \cup \text{active set}$ .  
If  $\frac{\partial \|y - Ax\|^2}{\partial x_i} < -\gamma$ , then set  $\theta_i := 1$ , *active set*  $:= \{i\} \cup \text{active set}$ .
- 3 Feature-sign step:  
Let  $\hat{A}$  be a submatrix of  $A$  that contains only the columns corresponding to the *active set*.  
Let  $\hat{x}$  and  $\hat{\theta}$  be subvectors of  $x$  and  $\theta$  corresponding to the *active set*.  
Compute the analytical solution to the resulting unconstrained QP ( $\min_{\hat{x}} \|y - \hat{A}\hat{x}\|^2 + \gamma \hat{\theta}^\top \hat{x}$ ):  
$$\hat{x}_{\text{new}} := (\hat{A}^\top \hat{A})^{-1} (\hat{A}^\top y - \gamma \hat{\theta}/2),$$
  
Perform a discrete line search on the closed line segment from  $\hat{x}$  to  $\hat{x}_{\text{new}}$ :  
Check the objective value at  $\hat{x}_{\text{new}}$  and all points where any coefficient changes sign.  
Update  $\hat{x}$  (and the corresponding entries in  $x$ ) to the point with the lowest objective value.  
Remove zero coefficients of  $\hat{x}$  from the *active set* and update  $\theta := \text{sign}(x)$ .
- 4 Check the optimality conditions:
  - (a) Optimality condition for nonzero coefficients:  $\frac{\partial \|y - Ax\|^2}{\partial x_j} + \gamma \text{sign}(x_j) = 0, \forall x_j \neq 0$   
If condition (a) is not satisfied, go to Step 3 (without any new activation); else check condition (b).
  - (b) Optimality condition for zero coefficients:  $\left| \frac{\partial \|y - Ax\|^2}{\partial x_j} \right| \leq \gamma, \forall x_j = 0$   
If condition (b) is not satisfied, go to Step 2; otherwise return  $x$  as the solution.

# 迭代收缩阈值算法(ISTA)

- Iterative Shrinkage Thresholding Algorithm (ISTA)

- 考虑 $L_1$ -最小化问题  $\min_{\mathbf{x}} \lambda \|\mathbf{x}\|_1 + \frac{1}{2} \|A\mathbf{x} - \mathbf{c}\|_2^2$

- 令  $f(\mathbf{x}) = \frac{1}{2} \|A\mathbf{x} - \mathbf{c}\|_2^2$

- 在 $\mathbf{x}_k$ 处, 对 $f(\mathbf{x})$ 进行2阶泰勒级数展开, 其中 $L$ 为Lipschitz常数:

$$f(\mathbf{x}) \leq Q(\mathbf{x}, \mathbf{x}_k) = f(\mathbf{x}_k) + \langle \mathbf{x} - \mathbf{x}_k, \nabla f(\mathbf{x}_k) \rangle + \frac{L}{2} \|\mathbf{x} - \mathbf{x}_k\|_2^2$$

- 则  $\mathbf{x}_{k+1} = \arg \min_{\mathbf{x}} \lambda \|\mathbf{x}\|_1 + Q(\mathbf{x}, \mathbf{x}_k)$

$$= \arg \min_{\mathbf{x}} \lambda \|\mathbf{x}\|_1 + \frac{L}{2} \left\| \mathbf{x} - \left( \mathbf{x}_k - \frac{1}{L} \nabla f(\mathbf{x}_k) \right) \right\|_2^2$$

— ISTA算法:

- 令 $k=0$ , 初始化 $\mathbf{x}_0$ ; 若不满足收敛条件, 计算 $\mathbf{x}_{k+1}$ , 并令 $k \leftarrow k+1$

# 快速迭代收缩阈值算法(FISTA)

- Fast Iterative Shrinkage Thresholding Algorithm (FISTA)

— 考虑 $L_1$ -最小化问题  $\min_{\mathbf{x}} \lambda \|\mathbf{x}\|_1 + f(\mathbf{x})$

- 初始化:  $\mathbf{y}_k = \mathbf{x}_{k-1}$ ,  $t_k = 1$ ,  $k=1$

- 在 $\mathbf{y}_k$ 处, 对 $f(\mathbf{x})$ 进行2阶泰勒级数展开, 其中 $L$ 为Lipschitz常数:

$$f(\mathbf{x}) \leq Q(\mathbf{x}, \mathbf{y}_k) = f(\mathbf{y}_k) + \langle \mathbf{x} - \mathbf{y}_k, \nabla f(\mathbf{y}_k) \rangle + \frac{L}{2} \|\mathbf{x} - \mathbf{y}_k\|_2^2$$

- 则  $\mathbf{x}_k = \arg \min_{\mathbf{x}} \lambda \|\mathbf{x}\|_1 + \frac{L}{2} \left\| \mathbf{x} - \left( \mathbf{y}_k - \frac{1}{L} \nabla f(\mathbf{y}_k) \right) \right\|_2^2$

$$t_{k+1} = (1 + \sqrt{1 + 4t_k^2})/2, \quad \mathbf{y}_{k+1} = \mathbf{x}_k + (t_k - 1)(\mathbf{x}_k - \mathbf{x}_{k-1})/t_{k+1}$$

## FISTA算法:

- 初始化 $\mathbf{x}_0$ , 令  $\mathbf{y}_k = \mathbf{x}_{k-1}$ ,  $t_k = 1$ ,  $k=1$ ; 若不满足收敛条件, 不断计算 $\mathbf{x}_k$ ,  $t_{k+1}$ ,  $\mathbf{y}_{k+1}$ , 并令 $k \leftarrow k+1$

[1] Beck, A; Teboulle, M (2009). "A fast iterative shrinkage-thresholding algorithm for linear inverse problems". SIAM J. Imaging Science, pp. 183–202.

神经计算-Neural Computation 模式识别与智能系统实验室

# 秩最小化问题

- 矩阵的最佳低秩近似问题:

$$\min_D \|D - X\|_F^2 \quad \text{s.t.} \quad \text{rank}(D) \leq r$$

- 对矩阵 $X$ 进行奇异值分解(Singular Value Decomposition: SVD), 得出:

$$X = USV^T$$

- 那么, 矩阵 $X$ 的最佳低秩近似为  $D^* = U_r S_r V_r^T$   
其中  $S_r = \text{diag}(\sigma_1, \sigma_2, \dots, \sigma_r), \sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_r \geq 0$

# 秩最小化问题

- 矩阵填充问题:

$$\min_D \text{rank}(D) \text{ s.t. } P_\Omega(D) = P_\Omega(X)$$



放松为:

$$\min_D \|D\|_* \text{ s.t. } P_\Omega(D) = P_\Omega(X)$$

— 奇异值阈值化(Singular Value Thresholding: SVT)算法

[1] J.-F. Cai, E. J. Candès, Z. Shen: A singular value thresholding algorithm for matrix completion, SIAM Journal of Optimization 20 (4) (2008) 1956–1982.

# SVT算子

- 最优化问题

$$\min_D \lambda \|D\|_* + \frac{1}{2} \|D - X\|_F^2$$

- 其中\*表示矩阵的核(Nuclear)范数, 等于D的奇异值的和

其最优解为

$$D^* = \arg \min_D \lambda \|D\|_* + \frac{1}{2} \|D - X\|_F^2 = UT_\lambda(S)V^T$$

- 其中 $[U, S, V] = \text{svd}(X)$ 为矩阵X的奇异值分解(SVD: Singular Value Decomposition)
- $T_\lambda(S)$  表示对矩阵对角线上的元素进行Soft Thresholding处理

[1] J.-F. Cai, E. J. Candès, Z. Shen: A singular value thresholding algorithm for matrix completion, SIAM Journal of Optimization 20 (4) (2008) 1956–1982.

# 其它非可微目标函数最小化问题

- RPCA问题 (核范数+ $L_1$ 范数)

$$\min_{D,E} \|D\|_* + \lambda \|E\|_1 \quad \text{s.t.} \quad X = D + E$$

- SRC问题:

$$\min_{\mathbf{x}, \mathbf{e}} \|\mathbf{x}\|_1 + \lambda \|\mathbf{e}\|_1 \quad \text{s.t.} \quad \mathbf{y} = A\mathbf{x} + \mathbf{e}$$

- SSC问题:

$$\min_{C,E,G} \|C\|_1 + \lambda \|E\|_1 + \gamma \|G\|_F^2 \quad \text{s.t.} \quad X = XC + E + G, \quad \text{diag}(C) = 0$$

- LRR问题:

$$\min_{Z,E} \|Z\|_* + \lambda \|E\|_{2,1} \quad \text{s.t.} \quad X = XZ + E$$



# 求解一般的目标函数不可导优化问题

- 增广拉格朗日乘子法
  - **Augmented Lagrange Multiplier: ALM**
- 乘子的交替方向法
  - **Alternating Direction Method of Multipliers: ADMM**

[1] Dimitri P. Bertsekas: Constrained Optimization and Lagrange Multiplier Methods, 1982.

[2] S. Boyd, et al. : Distributed Optimization and Statistical Learning via the Alternating Direction Method of Multipliers, FTML 2010.

[3] Lin, Chen, Wu, and Ma, “*The Augmented Lagrange Multiplier Method for Exact Recovery of Corrupted Low-Rank Matrix*”, 2009.

神经计算-Neural Computation 模式识别与智能系统实验室

# 增广拉格朗日乘子法(ALM)

- 考虑如下有约束优化问题

$$\min_{\mathbf{x}} f(\mathbf{x}) \quad \text{s.t.} \quad A\mathbf{x} = \mathbf{b}$$

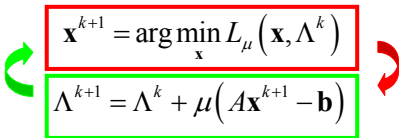
- 建立拉格朗日辅助函数

$$L_0(\mathbf{x}, \Lambda) = f(\mathbf{x}) + \Lambda^T (A\mathbf{x} - \mathbf{b})$$

- 建立增广拉格朗日辅助函数

$$L_{\mu}(\mathbf{x}, \Lambda) = f(\mathbf{x}) + \Lambda^T (A\mathbf{x} - \mathbf{b}) + \frac{\mu}{2} \|A\mathbf{x} - \mathbf{b}\|_2^2$$

- 增广拉格朗日乘子法(Augmented Lagrange Method)


$$\begin{aligned} \mathbf{x}^{k+1} &= \arg \min_{\mathbf{x}} L_{\mu}(\mathbf{x}, \Lambda^k) \\ \Lambda^{k+1} &= \Lambda^k + \mu(A\mathbf{x}^{k+1} - \mathbf{b}) \end{aligned}$$

也叫乘子法(Method of Multipliers)

Dimitri P. Bertsekas: Constrained Optimization and Lagrange Multiplier Methods, 1982

神经计算-Neural Computation 模式识别与智能系统实验室

# 乘子的交替方向法 (ADMM)

ADMM: Alternating Direction Method of Multipliers

- 考虑有约束优化问题

$$\min_{\mathbf{x}, \mathbf{z}} f(\mathbf{x}) + g(\mathbf{z}) \quad \text{s.t.} \quad A\mathbf{x} + B\mathbf{z} = \mathbf{c}$$

- 建立Augmented Lagrangian

$$L_{\mu}(\mathbf{x}, \mathbf{z}, \Lambda) = f(\mathbf{x}) + g(\mathbf{z}) + \Lambda^T (A\mathbf{x} + B\mathbf{z} - \mathbf{c}) + \frac{\mu}{2} \|A\mathbf{x} + B\mathbf{z} - \mathbf{c}\|_2^2$$

- ADMM 算法由下列迭代构成:

$$\begin{aligned} (\mathbf{x}^{k+1}, \mathbf{z}^{k+1}) &= \arg \min_{\mathbf{x}, \mathbf{z}} L_{\mu}(\mathbf{x}, \mathbf{z}, \Lambda^k) \\ \Lambda^{k+1} &= \Lambda^k + \mu(A\mathbf{x}^{k+1} + B\mathbf{z}^{k+1} - \mathbf{c}) \end{aligned}$$

乘法法(MM: Method of Multipliers)

$$\begin{aligned} \mathbf{x}^{k+1} &= \arg \min_{\mathbf{x}} L_{\mu}(\mathbf{x}, \mathbf{z}^{k+1}, \Lambda^k) \\ \mathbf{z}^{k+1} &= \arg \min_{\mathbf{z}} L_{\mu}(\mathbf{x}^{k+1}, \mathbf{z}, \Lambda^k) \\ \Lambda^{k+1} &= \Lambda^k + \mu(A\mathbf{x}^{k+1} + B\mathbf{z}^{k+1} - \mathbf{c}) \end{aligned}$$

[1] Zhouchen Lin et al., Fast Convex Optimization Algorithms for Exact Recovery of a Corrupted Low-Rank Matrix, Technical Report, UIUC, August 2009.

[2] S. Boyd, et al.: Distributed Optimization and Statistical Learning via the Alternating Direction Method of Multipliers, FTML 2010. 59

神经计算-Neural Computation 模式识别与智能系统实验室

# ALM / ADMM应用举例: 1 (1/4)

- 考虑下述L1最小化问题

$$\arg \min_{\mathbf{x}} \frac{1}{2} \|\mathbf{A}\mathbf{x} - \mathbf{b}\|_2^2 + \lambda \|\mathbf{x}\|_1$$

- 该问题等价于下述有约束L1最小化问题

$$\arg \min_{\mathbf{x}} \frac{1}{2} \|\mathbf{A}\mathbf{y} - \mathbf{b}\|_2^2 + \lambda \|\mathbf{x}\|_1 \quad \text{s.t.} \quad \mathbf{y} = \mathbf{x}$$

- 构造增广(Augmented)拉格朗日辅助函数

$$L(\mathbf{x}, \mathbf{y}, \Lambda) = \|\mathbf{A}\mathbf{y} - \mathbf{b}\|_2^2 + \lambda \|\mathbf{x}\|_1 + \langle \mathbf{y} - \mathbf{x}, \Lambda \rangle + \frac{\mu}{2} \|\mathbf{y} - \mathbf{x}\|_2^2$$

- 求解上述无约束优化问题

# ALM / ADMM应用举例: 1 (2/4)

- 求解无约束优化问题

$$L(\mathbf{x}, \mathbf{y}, \Lambda) = \|\mathbf{A}\mathbf{y} - \mathbf{b}\|_2^2 + \lambda \|\mathbf{x}\|_1 + \langle \mathbf{y} - \mathbf{x}, \Lambda \rangle + \frac{\mu}{2} \|\mathbf{y} - \mathbf{x}\|_2^2$$

– 交替求解下列子优化问题, 直到收敛:

Primal updating: minimization

同时优化 $\mathbf{x}$   
和 $\mathbf{y}$ 可能存  
在困难

$$\arg \min_{(\mathbf{x}, \mathbf{y})} L(\mathbf{x}, \mathbf{y}, \Lambda) = \|\mathbf{A}\mathbf{y} - \mathbf{b}\|_2^2 + \lambda \|\mathbf{x}\|_1 + \langle \mathbf{y} - \mathbf{x}, \Lambda \rangle + \frac{\mu}{2} \|\mathbf{y} - \mathbf{x}\|_2^2$$

Dual updating: maximization

$$\arg \max_{\Lambda} L(\mathbf{x}, \mathbf{y}, \Lambda) = \langle \mathbf{y} - \mathbf{x}, \Lambda \rangle$$

# ALM / ADMM应用举例: 1 (3/4)

- 求解无约束优化问题

$$L(\mathbf{x}, \mathbf{y}, \Lambda) = \|\mathbf{A}\mathbf{y} - \mathbf{b}\|_2^2 + \lambda \|\mathbf{x}\|_1 + \langle \mathbf{y} - \mathbf{x}, \Lambda \rangle + \frac{\mu}{2} \|\mathbf{y} - \mathbf{x}\|_2^2$$

– 交替求解下列容易求解的子问题, 直到收敛:

Primal updating: minimization

$$\arg \min_{\mathbf{x}} L(\mathbf{x}, \mathbf{y}, \Lambda) = \lambda \|\mathbf{x}\|_1 + \langle \mathbf{y} - \mathbf{x}, \Lambda \rangle + \frac{\mu}{2} \|\mathbf{y} - \mathbf{x}\|_2^2$$

$$\arg \min_{\mathbf{y}} L(\mathbf{x}, \mathbf{y}, \Lambda) = \|\mathbf{A}\mathbf{y} - \mathbf{b}\|_2^2 + \langle \mathbf{y} - \mathbf{x}, \Lambda \rangle + \frac{\mu}{2} \|\mathbf{y} - \mathbf{x}\|_2^2$$

$$\arg \max_{\Lambda} L(\mathbf{x}, \mathbf{y}, \Lambda) = \langle \mathbf{y} - \mathbf{x}, \Lambda \rangle$$

Dual updating: maximization

# ALM / ADMM应用举例: 1 (4/4)

- 求解无约束优化问题

$$L(\mathbf{x}, \mathbf{y}, \Lambda) = \|\mathbf{A}\mathbf{y} - \mathbf{b}\|_2^2 + \lambda \|\mathbf{x}\|_1 + \langle \mathbf{y} - \mathbf{x}, \Lambda \rangle + \frac{\mu}{2} \|\mathbf{y} - \mathbf{x}\|_2^2$$

– 交替求解下列容易求解的子问题, 直到收敛:

Primal updating: minimization

$$\arg \min_{\mathbf{x}} \lambda \|\mathbf{x}\|_1 + \frac{\mu}{2} \|\mathbf{x} - \mathbf{y} - \Lambda / \mu\|_2^2 = T_{\lambda/\mu}(\mathbf{y}_{k+1} + \Lambda_{k+1} / \mu)$$

$$\arg \min_{\mathbf{y}} \|\mathbf{A}\mathbf{y} - \mathbf{b}\|_2^2 + \langle \mathbf{y} - \mathbf{x}, \Lambda \rangle + \frac{\mu}{2} \|\mathbf{y} - \mathbf{x}\|_2^2 = (\mathbf{A}^T \mathbf{A} + \mu \mathbf{I})^{-1} (\mathbf{A}^T \mathbf{b} + \mu \mathbf{x} - \Lambda)$$

$$\Lambda_{k+1} = \Lambda_k + \mu_{k+1} (\mathbf{y}_{k+1} - \mathbf{x}_{k+1})$$

Dual updating: maximization

# ALM / ADMM应用举例: 2 (1/2)

- 考虑矩阵填充问题

$$\min_D \|D\|_* \quad \text{s.t.} \quad P_\Omega(D) = P_\Omega(X)$$

- 构造增广(Augmented)拉格朗日辅助函数

$$L(D, \Lambda) = \|D\|_* + \langle \Lambda, P_\Omega(D - X) \rangle + \frac{\mu}{2} \|P_\Omega(D - X)\|_F^2$$

- 如何更新D?

- 保留与D有关的项, 记为 $g(D)$ , 对 $g(D)$ 在 $D_k$ 处进行Taylor级数展开

$$\begin{aligned} g(D) &= \|D\|_* + \langle \Lambda, P_\Omega(D - X) \rangle + \frac{\mu}{2} \|P_\Omega(D - X)\|_F^2 \\ &\leq \|D\|_* + g(D_k) + \langle \nabla g(D_k), D - D_k \rangle + \frac{\eta\mu}{2} \|D - D_k\|_F^2 \\ &= h(D) \end{aligned}$$

$$\text{其中 } \nabla g(D_k) = P_\Omega(\Lambda_k) + \mu P_\Omega(D_k - X), \quad \eta = 1$$



# ALM / ADMM应用举例: 2 (2/2)

- 通过求解 $h(D)$ 来更新 $D$ :

$$D_{k+1} = \arg \min_D h(D) = \|D\|_* + g(D_k) + \langle \nabla g(D_k), D - D_k \rangle + \frac{\eta\mu}{2} \|D - D_k\|_F^2$$

– 交替求解下列容易求解的子问题, 直到收敛:

Primal updating: minimization

$$\begin{aligned} D_{k+1} = \arg \min_D h(D) &= \frac{1}{\eta\mu} \|D\|_* + \frac{1}{2} \|D - D_k + \nabla g(D_k) / \eta\mu\|_F^2 \\ &= SVT_{1/\eta\mu}(D_k - \nabla g(D_k) / \eta\mu) \end{aligned}$$



Dual updating: maximization

$$\Lambda_{k+1} = \Lambda_k + \mu_{k+1} P_{\Omega}(D_{k+1} - X)$$

# 扩展阅读推荐

- 压缩感知的简介
  - Emmanuel Candes and Michael Wainwright: **An Introduction to Compressive Sampling**, 2010.
  - David Donoho, "Compressed sensing," **IEEE Trans. on Information Theory**, 52(4), pp. 1289 - 1306, Apr. 2006.
- 理论论文精要
  - 稀疏编码
    - Emmanuel Candès and Terence Tao, "Decoding by linear programming" **IEEE Trans. on Information Theory**, 51(12), pp. 4203 - 4215, December 2005
    - Emmanuel Candès, Justin Romberg, and Terence Tao, "Robust uncertainty principles: Exact signal reconstruction from highly incomplete frequency information," **IEEE Trans. on Information Theory**, 52(2) pp. 489 - 509, Feb. 2006.
  - 矩阵填充
    - E. Candès, B. Recht, Exact matrix completion via convex optimization, **Foundations of Computational Mathematics** 9 (2008) 717–772.
    - E. Candès, T. Tao, The power of relaxation: Near-optimal matrix completion, **IEEE Transactions on Information Theory** 56 (5) (2010) 2053–2080.
    - B. Recht, A simpler approach to matrix completion, **Journal of Machine Learning Research** 12 (2011) 3413–3430.

# 扩展阅读推荐

- 优化算法
  - **S. Boyd, et al. : Distributed Optimization and Statistical Learning via the Alternating Direction Method of Multipliers, Foundation and Trends in Machine Learning, Vol.3, No.1, pp.1-122, 2010.**
  - **Neal Parikh and Stephen Boyd: Proximal Algorithms, Foundations and Trends in Optimization, Vol. 1, No. 3, pp.1-108, 2013.**
- 压缩感知与稀疏表示的专著
  - **Michael Elad: Sparse and Redundant Representations: From Theory to Application in Signal and Image Processing, 2010.**
  - **Michael Elad et al: Compressed Sensing: Theory and Applications, 2012.**
- 数据建模Beyond PCA:
  - **R. Vidal, Y. Ma, and S. Sastry: Generalized Principal Component Analysis. Springer Verlag, 2015. (In press)**

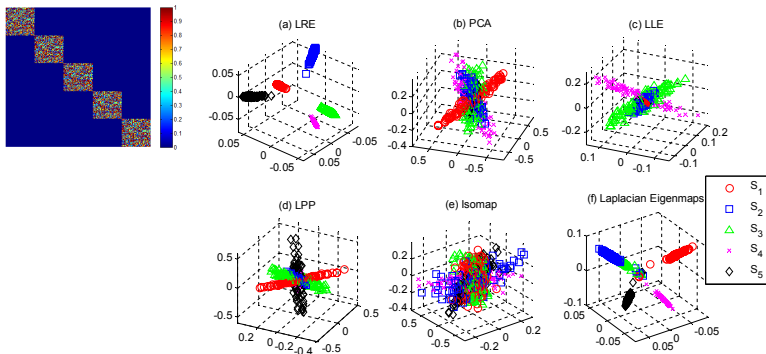
# Proximal Method

- Proximal Operator:  $\text{prox}_f : \mathbb{R}^n \rightarrow \mathbb{R}^n$  of  $f$ 
  - $f$ 是一个**convex** 函数
  - $$\text{prox}_f(v) = \underset{x}{\operatorname{argmin}} \left( f(x) + (1/2)\|x - v\|_2^2 \right)$$
  - **proximal**算子是在使用**closed-form**解去求解一个小的**convex**优化问题
- Proximal 算法
  - 用于使用目标函数的**proximal**算子求解一个凸优化问题

Neal Parikh and Stephen Boyd: Proximal Algorithms, Foundations and Trends in Optimization, Vol. 1, No. 3, pp.1-108, 2013.

# LRE (Low-Rank Embedding)


- 低秩嵌入(LRE)降维算法



C.-G. Li et al.: Dimensionality Reduction by Low-Rank Embedding, ISCIIDE 2012.

神经计算-Neural Computation 模式识别与智能系统实验室

# 基排序: Bases Sorting



[1] Chun-Guang Li, et al. Bases Sorting: Generalizing the Concept of Frequency for Over-complete Dictionaries, *Neurocomputing*, Vol.115, Sept. 4, 2013, pp.192–200.

神经计算-*Neural Computation* 模式识别与智能系统实验室

70

# 结构化的稀疏子空间聚类(S<sup>3</sup>C)

- 结构化SSC可以同时学习表示矩阵C和子空间分割矩阵Q:

$$\min_{C, E, Q} \|C\|_{1, Q} + \lambda \|E\|_1$$

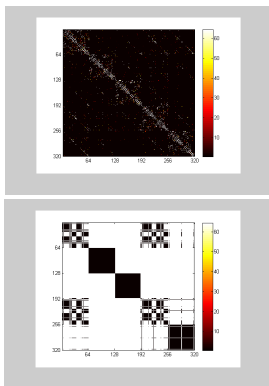
$$\text{s.t. } X = XC + E, \text{diag}(C) = 0, Q \in \Gamma$$

- 其中结构化L<sub>1</sub>范数定义如下:

$$\|C\|_{1, Q} = \|(\alpha \Theta + 11^T) \odot C\|_1$$

Q为子空间分割矩阵

$$\Theta_{ij} = \frac{1}{2} \|\mathbf{q}^{(i)} - \mathbf{q}^{(j)}\|_2^2, \quad Q_{N \times k} = \begin{pmatrix} \mathbf{q}^{(1)} \\ \mathbf{q}^{(2)} \\ \dots \\ \mathbf{q}^{(N)} \end{pmatrix}$$



[1] Chun-Guang Li and René Vidal, "Structured Sparse Subspace Clustering: A Unified Optimization Framework", In: IEEE CVPR 2015.

# 可扩展(Scalable)的子空间聚类算法

- 基于OMP的稀疏子空间聚类
  - 使用**OMP**快速求解**SSC**中的稀疏表示系数计算问题
  - 并给出最优解正确性的理论保证

[1] Chong You and R. Vidal, "Sparse Subspace Clustering by Orthogonal Matching Pursuit", CVPR 2016.

- 基于弹性网络的可扩展子空间聚类算法
  - **L1+L2**
  - 基于主动集的快速求解算法
  - 解的正确性的理论保证
  - 连通性的分析

[2] Chong You, Chun-Guang Li, Daniel Robinson, and Rene Vidal, "Oracle Based Active Set Algorithm for Scalable Elastic Net Subspace Clustering", CVPR 2016.



These slides are adopted from Dr. Chunguang Li.

